

Guía de Actividades Práctico-Experimentales Nro. 012

• Datos Generales

Asignatura	Machine Learning
Ciclo	8 A
Unidad	1
Resultado de aprendizaje de la unidad	Proporciona una explicación del papel del aprendizaje automático en la ingeniería informática, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Título de la práctica	Implementación de una arquitectura RAG (Retrieval-Augmented Generation) para consulta inteligente de documentos.
Nombre del docente	Genoveva Jackelinne Suing Albito
Nombre del técnico docente	Ramiro Rene Rivera Guamán
Fecha inicio	Lunes 13 de julio de 2026
Horario	09h30 – 11h30
Fecha fin	Jueves 17 de julio de 2026
Horario	11h30 – 13h30
Lugar	Aula virtual de la asignatura
Tiempo planificado en el Sílabo	4 horas

• Objetivo(s) de la Práctica:

Implementa una arquitectura RAG mediante Python, utilizando documentos como base de conocimiento, modelos de embeddings y un modelo de lenguaje, con el propósito de desarrollar un sistema capaz de recuperar información relevante y generar respuestas contextualizadas.

• Materiales y reactivos:

Software:

- Python 3.10+
- Google Colab o Jupyter Notebook
- Navegador web

Librerías:

- LangChain

- ChromaDB
- Sentence Transformers
- Hugging Face Transformers
- Pypdf
- Faiss-cpu (opcional)

● Documentos

Utilizar al menos tres documentos en formato PDF o contextos relacionados con un tema específico, por ejemplo:

- Reglamentos universitarios.
- Manuales técnicos.
- Artículos científicos.
- Normas técnicas.
- Documentación institucional.

En la página institucional se tiene acceso a recursos como:

- Resoluciones: <https://unl.edu.ec/gaceta>
- Manuales: <https://siaaf.unl.edu.ec/>
- Plan estratégico de desarrollo institucional: <https://unl.edu.ec/> sección universidad.

● Equipos y herramientas

- Aula de laboratorio.
- Laptop con sistema operativo Windows/Linux.
- Recursos de Google
- Acceso al EVA para subir evidencias

● Procedimiento / Metodología

1) Introducción

Los modelos de lenguaje de gran escala (LLMs) poseen una gran capacidad para generar texto, pero presentan limitaciones cuando deben responder preguntas sobre información específica o actualizada. La arquitectura Retrieval-Augmented Generation (RAG) supera esta limitación combinando un sistema de recuperación de información con un modelo de lenguaje, permitiendo consultar documentos externos antes de generar una respuesta.

En esta práctica, el estudiante desarrollará una aplicación básica de RAG utilizando Python y herramientas de código abierto para construir un asistente capaz de responder preguntas a partir de una colección de documentos.

2) Parte 1. Preparación del entorno

- Instalar las librerías necesarias.
- Importar los módulos requeridos.
- Verificar el funcionamiento del entorno.

3) Parte 2. Construcción de la base documental

- Cargar los documentos seleccionados y realizar: lectura del contenido, fragmentación (*chunking*) y almacenamiento temporal.
- Registrar: número de documentos y número de fragmentos generados.

4) Parte 3. Generación de embeddings

Crear representaciones vectoriales de los fragmentos utilizando un modelo de embeddings.

Ejemplos:

- all-MiniLM-L6-v2
- BAAI/bge-small-en
- sentence-transformers

5) Parte 4. Construcción de la base vectorial

Crear una base vectorial utilizando:

- ChromaDB
- Dataframe (como el ejemplo adjunto)
- FAISS (opcional)

6) Parte 5. Implementación del sistema RAG

Desarrollar un flujo similar al siguiente esquema:




Figura 1: Ejemplo de flujo para implementación de sistema RAG

7) Parte 6. Pruebas del sistema

Realizar al menos cinco consultas diferentes y registrar para cada una:

- Pregunta realizada
- Fragmentos recuperados
- Respuesta generada.
- Observaciones.

8) Parte 7. Análisis de resultados

Analizar y comparar cómo influye la calidad de los documentos sobre el desempeño del sistema sobre:

- Calidad de las respuestas
- Pertinencia de los documentos recuperados
- Posibles errores de recuperación

→ En la presente actividad práctica se aplica la metodología de: Aprendizaje Basado en Problemas (ABP), Aprendizaje basado en experimentación y Aprendizaje colaborativo.

● Resultados esperados:

Al finalizar la práctica el estudiante deberá entregar:

- Notebook en Python (.ipynb).
- Documentos utilizados como base de conocimiento.
- Capturas del funcionamiento del sistema.
- Informe técnico

● Preguntas de Control:

Responda de forma clara y fundamentada las siguientes preguntas:

1. ¿Qué problema resuelve una arquitectura RAG?
2. ¿Cuál es la diferencia entre un LLM tradicional y un sistema RAG?
3. ¿Qué función cumplen los embeddings?
4. ¿Por qué se utilizan bases de datos vectoriales?
5. ¿Qué importancia tiene el proceso de *chunking*?
6. ¿Qué ocurriría si los documentos contienen información incorrecta o desactualizada?
7. ¿Qué ventajas ofrece RAG frente al Fine-Tuning para incorporar conocimiento específico?
8. ¿En qué aplicaciones de ingeniería podría implementarse una arquitectura RAG?

● Evaluación

La práctica será calificada y tiene como finalidad evaluar la capacidad del estudiante para implementar una arquitectura RAG funcional, integrar herramientas modernas para recuperación de información y analizar críticamente el desempeño del sistema desarrollado

Criterio	Descripción	Puntaje
Preparación e indexación de documentos	Selecciona, procesa e indexa correctamente los documentos, aplicando fragmentación (<i>chunking</i>) y generación de embeddings.	2.0
Implementación de la	Implementa correctamente el flujo de recuperación de información e integración con	3.0

arquitectura RAG	el modelo de lenguaje.	
Pruebas y evaluación del sistema	Realiza consultas variadas, analiza la pertinencia de las respuestas y evidencia el funcionamiento del sistema.	2.0
Informe técnico	Presenta un informe organizado con metodología, resultados, discusión y conclusiones fundamentadas.	1.5
Calidad del notebook y documentación	Código organizado, documentado y reproducible, con comentarios y evidencias del funcionamiento.	1.5

• Bibliografía

- Lewis, P., et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS.
- Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. 3.^a ed.
- Russell, S., & Norvig, P. *Artificial Intelligence: A Modern Approach*. 4.^a ed.

• Elaboración y Aprobación

Elaborado por	Ing. Genoveva Suing Albito Docente	 Validar únicamente en FirmaEC. Firmado electrónicamente por: GENOVEVA JACKELINNE SUIING ALBITO
Aplicado por	Ing. Ramiro Rivera Guamán Técnico Docente	
Aprobado por	Ing. Edison Coronel Romero Director de Carrera	